

CS182 Introduction to Machine Learning


Recitation 10

2025.5.21

Outline


- Recommendation system
- PCA
- Kmeans

Recommendation system



Sparse -> Low rank

Matrix Factorization




$r_{i,j}$ 是用户对物品的评分, 打分较少, 所以 R 是稀疏低秩矩阵

$\text{Rank}(R) = k \ll \min(m, n)$, k 是超参数

$$R = UV^T$$


预测用户 i 对物品 j 的评分: $\hat{r}_{ij} = U_i V_j^T$

Matrix Factorization



$$J(U, V) = \|R - UV^\top\|_F^2 + \lambda(\|U\|_F^2 + \|V\|_F^2)$$


LoRA (Low Rank Adaptation)




$$W_0 + \Delta W = W_0 + BA \quad B \in \mathbb{R}^{d \times r}, A \in \mathbb{R}^{r \times k} \quad r \ll \min(d, k)$$

$$h = W_0 x + \Delta W x = W_0 x + BAx$$

PCA (Principal Component Analysis)



PCA



- 最大化投影后的方差 / 最小化重建误差

PCA

1. Centerization

$$X = X - \mu$$

2. Eigenvalue Decomposition / SVD

$$X = U\Sigma V^\top$$


(U 是 XX^\top 的特征向量, V 是 $X^\top X$ 的特征向量)

3. 取出 V_1, V_2, \dots, V_k (假设数据矩阵式**行向量**拼起来)


4. Projection

$$X'_i = X_i[V_1, V_2, \dots, V_k]$$

PCA是特殊的Encoder-Decoder结构(线性)



Visualize Latent Space



其他降维方式


- PCA
- LDA
- t-SNE
- UMAP
- ...

Kmeans

$$\text{E-step: } z_i = \arg \min_k \|x_i - \mu_k\|_2^2$$

$$\text{M-step: } \mu_k = \frac{1}{n_k} \sum_{i: z_i=k} x_i$$

Initialization



Kmeans++

1. 从所有点中均匀随机选择一个, 作为第一个簇的中心 c_1 . 所有簇的中心的集合为

$$C = \{c_1\}$$

2. 对于每个非中心点 x_i , 计算 x_i 到 C 中每个簇中心的距离

$$D^2(x) = \min_{c \in C} \|x - c\|^2, \quad x \notin C$$

3. 选择下一个中心:

$$\Pr(x_i \text{被选作下一个中心}) = \frac{D^2(x_i)}{\sum_{x \notin C} D^2(x)}$$

4. 重复步骤2和步骤3, 直到 $|C| = k$